Práctica Fundamentos de Análisis de Imágenes: Panorama Image Stitching

Autores:
- Antía Sande Fernández
- Sergio Medina Hernández
- Martín Hernández Castaño

1. Introducción

El objetivo de esta práctica es aplicar técnicas fundamentales de análisis de imagen para la detección de objetos planos y la construcción de panoramas a partir de múltiples imágenes. Se abordan tres problemas progresivamente más complejos:

1. Detección de un objeto plano texturizado en una escena mediante homografías, junto con la inserción de una imagen con la perspectiva correcta.
2. Construcción de un panorama planar a partir de cinco imágenes ordenadas horizontalmente.
3. Generación de un panorama wide view usando siete imágenes, introduciendo proyecciones geométricas no planas y estrategias avanzadas de alineación y blending.

En cada parte se comparan distintos detectores, descriptores y estrategias de matching, analizando tanto la calidad visual como el coste computacional de cada etapa.

2. Parte 1: Detección planar basada en homografías

2.1 Planteamiento del problema

Se desea localizar un objeto plano y texturizado dentro de una imagen de escena. A partir de la homografía estimada entre el modelo y la escena, se inserta una nueva imagen sobre el plano detectado, respetando la perspectiva de la escena original.



Figura 1. Modelo, escena e imagen a insertar

2.2 Pipeline implementado

Se ha implementado un flujo de trabajo estándar en visión por computador para la localización de objetos planos mediante características locales. El proceso se divide en las siguientes cuatro etapas secuenciales:

1. **Detección y descripción (Feature Extraction):** Se identifican puntos de interés (*keypoints*) invariantes y se calculan sus vectores de características (*descriptors*) tanto en la imagen modelo como en la imagen de la escena. Esto se realiza utilizando detectores y descriptores robustos (como se detalla en la sección de experimentación, se han evaluado variantes binarias y de punto flotante).
2. **Emparejamiento de características (Feature Matching):** Se establecen correspondencias preliminares entre los descriptores de ambas imágenes utilizando una búsqueda de los k vecinos más cercanos (algoritmo KNN con $k = 2$). Para filtrar falsos positivos y resolver ambigüedades, se aplica el **test de razón de Lowe** (*Lowe's ratio test*), descartando aquellas coincidencias donde la distancia del primer vecino no es significativamente menor que la del segundo.
3. **Estimación geométrica robusta:** A partir de los emparejamientos filtrados ("buenos matches"), se calcula la matriz de homografía 3×3 que relaciona el plano del modelo con el de la escena. Para asegurar la robustez frente a *outliers* restantes, se utiliza el algoritmo iterativo **RANSAC** (*Random Sample Consensus*) dentro de la función de estimación.
4. **Proyección y composición (Warping):** Finalmente, utilizando la homografía optimizada, se aplica una transformación de perspectiva (*warp perspective*) a la imagen que se desea insertar para alinearla con la geometría de la escena. La fusión final se realiza mediante operaciones de enmascaramiento para integrar el contenido virtual sobre el objeto detectado.

2.3 Detectores y descriptores

Se han evaluado dos combinaciones:

- ORB: descriptor binario, rápido y eficiente, usando distancia Hamming.
- SIFT: descriptor en coma flotante, más robusto, usando distancia L2.

Ambos métodos se integran en una función común que devuelve el extractor, el tipo de norma y el tipo de descriptor.

2.4 Resultados visuales



Figura 2. Visualización de matches entre modelo y escena y inliers tras RANSAC para ORB.



Figura 3. Resultado final con la inserción para ORB.

Tras insertar la imagen sobre la escena se obtiene un resultado casi perfecto, dejando un pequeño espacio en el margen superior y la esquina inferior izquierda.



Figura 4. Visualización de matches entre modelo y escena y inliers tras RANSAC para SIFT.



Figura 5. Resultado final con la inserción para SIFT.

Se observa un resultado visualmente peor con SIFT frente a ORB, siendo más significativa la distorsión producida en la esquina inferior izquierda.

2.5 Resultados cuantitativos

Para cada método se han medido:

- Número de keypoints detectados en el modelo y en la escena.
- Número de matches tras el ratio test.
- Número de inliers obtenidos por RANSAC.
- Tiempo de detección y descripción.
- Tiempo de matching.
- Tiempo de estimación de la homografía.

	metodo	kp_modelo	kp_escena	matches	inliers	t_detect_desc	t_match	t_ransac
0	orb	4000	4000	106	58	0.226309	0.028076	0.002942
1	sift	4000	4000	131	44	2.760462	0.044089	0.009076

Tabla 1. Resultados cuantitativos para ORB y SIFT.

2.6 Discusión

Los resultados cuantitativos refuerzan la conclusión visual anterior, produciendo ORB más inliers que SIFT y teniendo una eficiencia del Match (Ratio Inliers/Matches) mayor. Para ORB, el 54,7% de los matches fueron buenos, frente a únicamente el 33,6% en el caso de SIFT.

Además, ORB presenta tiempos de ejecución significativamente menores, lo que lo hace especialmente interesante para aplicaciones en tiempo real.

3. Parte 2: Stitching planar de cinco imágenes

3.1 Objetivo

El objetivo de esta parte es construir un panorama planar a partir de cinco imágenes con solapamiento horizontal, entregadas en orden de izquierda a derecha. Se toma una imagen

de referencia (típicamente la central) y el resto se “rectifican” mediante homografías para alinearlas en el mismo plano, generando un mosaico final mediante warping y blending.

3.2 Metodología

El pipeline implementado sigue el esquema clásico de stitching planar:

1. **Detección y descripción de características (features)** en cada imagen.
   Se extraen puntos clave (keypoints) y descriptores locales (binarios o en coma flotante según el método). Esta etapa es crítica porque determina cuánta información “comparable” habrá entre imágenes y, por tanto, la estabilidad del alineamiento posterior.

2. **Matching entre imágenes adyacentes** (i→i+1).
   Como las imágenes están ordenadas, basta emparejar adyacentes. Para mejorar robustez se utiliza KNN matching y se aplica el ratio test de Lowe, que elimina correspondencias ambiguas (cuando el mejor match no es suficientemente mejor que el segundo). Esto reduce muchos outliers antes de RANSAC.

3. **Estimación robusta de homografías con RANSAC** por cada par adyacente.
   Aunque tras el ratio test quedan matches “buenos”, todavía hay outliers. RANSAC permite estimar una homografía Hi→i+1 usando solo un subconjunto consistente (inliers), descartando el resto. Esta etapa es la que realmente estabiliza la geometría del mosaico.

4. **Acumulación de transformaciones hacia una referencia**.
   Una vez se tienen homografías entre pares consecutivos, se componen para llevar cada imagen al sistema de coordenadas de la imagen de referencia.

   - Imágenes a la izquierda: se acumulan homografías “hacia la derecha” hasta la referencia.

   - Imágenes a la derecha: se acumulan homografías “hacia la izquierda” (o sus inversas) hasta la referencia. Esto evita que la referencia se deforme y minimiza distorsiones visuales globales.

5. **Creación de un lienzo común (canvas)**.
   Para saber el tamaño del panorama, se proyectan las esquinas de cada imagen ya transformada y se calcula el bounding box global. Con esto se define una traslación adicional para que todas las coordenadas queden en el rango positivo y quepan en el canvas.

6. **Warping al canvas + Blending**.
   Cada imagen se warppea al canvas con su homografía acumulada. Luego, como existen zonas de solape, se combina la información con una estrategia de blending (por ejemplo feathering) para suavizar transiciones y reducir costuras.

3.3 Métodos evaluados

Se compararon combinaciones de detector/descriptor y matcher:

- ORB: descriptor binario, matching con distancia Hamming y BF/FLANN.
- SIFT: descriptor en coma flotante , matching con distancia L2 y BF/FLANN.
- KAZE: características tipo “blob” en espacio no lineal, con descriptores en coma flotante, también con BF/FLANN.

Además, se evaluaron dos estrategias de matching:

- Brute Force (BF): compara descriptores de forma directa.
- FLANN: búsqueda aproximada de vecinos más cercanos, especialmente útil cuando el número de descriptores es elevado.

3.4 Benchmarking

Para cada combinación se registraron:

- mean_kps: número medio de keypoints por imagen (indica “riqueza” de features).
- mean_matches: matches medios tras ratio test.
- mean_inliers: inliers medios tras RANSAC (lo más representativo de la calidad geométrica).
- total_time: tiempo total del pipeline (detección+descripción+matching+RANSAC+warps+blend).
- **ok**: si se consigue construir un panorama coherente sin fallos.

En la Tabla 2 se observa que KAZE genera muchísimos keypoints (≈11.6k de media) y alcanza el mayor número de inliers (≈1274–1276), pero el coste temporal es alto (≈27 s). ORB es el más rápido (≈7.7 s con BF), pero con menor número de inliers (≈279). SIFT queda en un punto intermedio, con una cantidad de inliers notable (≈333–337) y tiempos moderados (≈17.7–21.6 s), con alta estabilidad visual.

Es decir, KAZE ofrece la mayor estabilidad geométrica (más inliers) pero es el más costoso; ORB es el más rápido pero menos fiable; SIFT+FLANN proporciona el mejor balance entre robustez y tiempo, por lo que se selecciona para el panorama final.

	method	matcher	total_time	mean_kps	mean_inliers	mean_matches	ok
5	kaze	flann	27.083869	11591.8	1275.75	2278.50	True
4	kaze	bf	27.196563	11591.8	1273.75	2207.25	True
3	sift	flann	21.630171	4000.4	337.25	642.75	True
2	sift	bf	17.698370	4000.4	333.50	632.50	True
1	orb	flann	20.930972	4000.0	315.50	450.50	True
0	orb	bf	7.665148	4000.0	278.75	409.50	True

Tabla 2. Benchmarking ordenado por número de inliers y tiempo total.

3.5 Resultado final

La combinación seleccionada para el resultado final fue SIFT + FLANN, ya que ofrece un buen compromiso entre:

- robustez (inliers suficientes y homografías estables),
- coste computacional razonable,
- y calidad visual en el panorama.

En la siguiente figura se muestra el panorama final obtenido con esta configuración (blending tipo feather), donde las cinco imágenes quedan alineadas sobre el plano de la imagen de referencia.

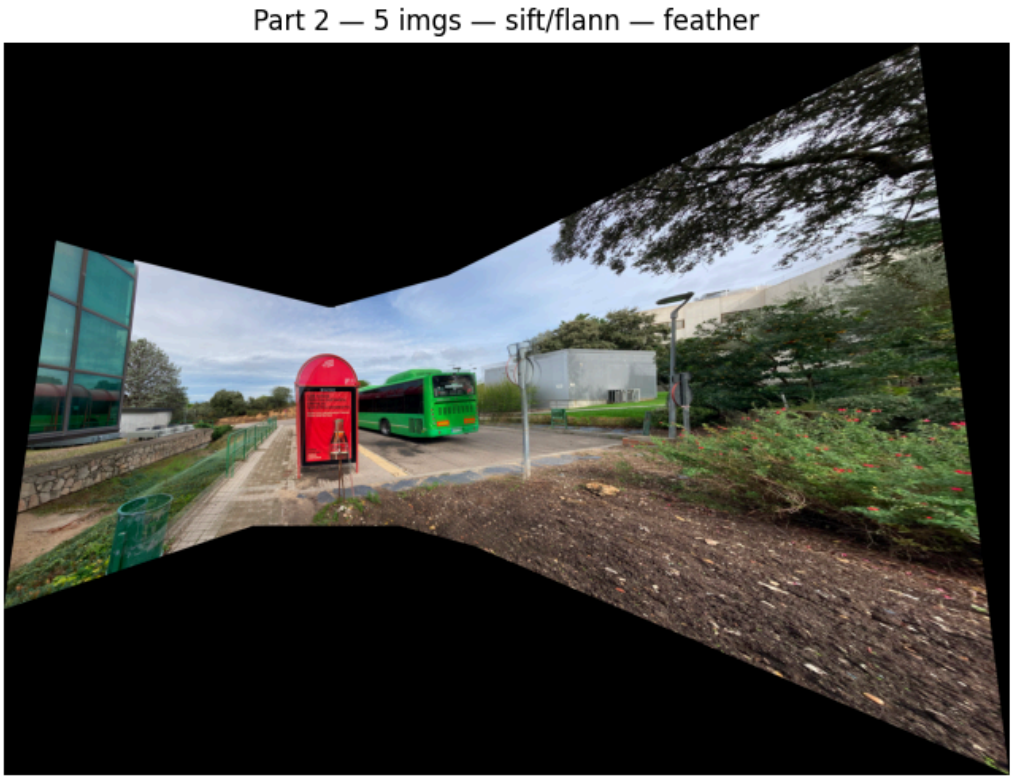


Figura 6. Imagen del panorama final obtenido con la mejor combinación (SIFT + FLANN).

	img	kps	t_detect	t_desc
0	0	4000	0.437528	0.333153
1	1	4000	0.424689	0.336119
2	2	4001	0.407271	0.327618
3	3	4000	0.418592	0.352861
4	4	4001	0.438030	0.338252

Tabla 3. Tiempos de detección y descripción por imagen.

Vemos el coste temporal de la extracción de características (detección + descripción) por imagen. Es importante porque esta etapa se ejecuta para todas las imágenes y suele dominar el tiempo total; además, si su comportamiento es estable entre capturas, el pipeline es predecible y las comparaciones entre métodos (benchmarking) son justas.

	pair	matches	inliers	t_match	t_ransac
0	0->1	1148	699	0.128971	0.001544
1	1->2	606	269	0.147499	0.004239
2	2->3	521	166	0.133701	0.011529
3	3->4	292	190	0.118045	0.000938

Tabla 4. Estadísticas de matching e inliers por par de imágenes.

En la tabla anterior se resume la calidad del alineamiento entre imágenes adyacentes: primero los matches tras el filtrado y, después, los inliers que RANSAC considera geométricamente consistentes. Es clave porque los inliers son los que realmente sostienen la homografía: si son suficientes, la transformación se estima de forma robusta y el panorama queda bien alineado; si un par tiene pocos inliers, ese enlace se convierte en el punto débil y es donde suelen aparecer desalineaciones y costuras visibles.

3.6 Discusión

En esta parte se observa que la calidad del stitching planar no depende tanto de acumular muchos matches, sino de conseguir suficientes inliers tras RANSAC, ya que son los que garantizan que la homografía entre pares adyacentes es consistente y evitan desalineaciones o costuras visibles. Los resultados reflejan el compromiso típico: ORB es el más rápido pero con menos soporte geométrico, mientras que KAZE logra la mayor robustez a costa de un tiempo alto . SIFT ofrece el mejor equilibrio, con inliers suficientes y tiempos moderados , y además los descriptores en coma flotante (SIFT/KAZE) suelen ser más robustos en zonas con poca textura. En este contexto, FLANN ayuda a acelerar el matching cuando hay muchos descriptores, compensando parte del coste de SIFT, por lo que SIFT+FLANN se justifica como la opción final al combinar estabilidad geométrica y eficiencia.

4. Parte 3: Panorama wide view con siete imágenes

4.1 Motivación

Al aumentar el número de imágenes, la hipótesis de plano deja de ser válida y aparecen distorsiones y drift. Para mitigar estos efectos se introducen proyecciones geométricas no planas y modelos de alineación más simples.

4.2 Proyección geométrica

Se implementan dos tipos de proyección:

- Proyección cilíndrica.
- Proyección esférica.

Estas proyecciones reducen la distorsión en los extremos del panorama y permiten un alineamiento más estable en panoramas amplios.

4.3 Alineación basada en traslación

Tras la proyección, se asume que la transformación dominante entre imágenes adyacentes es una traslación. Esta se estima de forma robusta mediante RANSAC sobre las diferencias entre keypoints emparejados.

Adicionalmente, se corrige el drift vertical ajustando una recta a las traslaciones acumuladas y eliminando la componente no deseada.

4.4 Blending

Se comparan dos estrategias de blending:

- Max weight: conserva bordes nítidos, pero puede introducir transiciones visibles.
- Multi band blending: produce transiciones más suaves entre imágenes, reduciendo artefactos.

4.5 Resultados



Figuras 7 y 8. Imágenes del panorama wide view usando max weight y multi band blending.

	pair	matches	inliers	dx	dy	t_match
0	0->1	1155	252	-531.023560	-20.701904	0.119380
1	1->2	1246	195	-320.681793	29.141968	0.119449
2	2->3	709	68	-670.169495	-49.279022	0.125676
3	3->4	647	33	-782.315186	56.235535	0.130470
4	4->5	483	33	-628.819702	-13.879456	0.129838
5	5->6	396	28	-628.767700	9.726501	0.117545

Tabla 5. Matches, inliers y traslaciones estimadas entre pares de imágenes.

La Figura 7 muestra el panorama wide view obtenido utilizando max-weight blending. Este método conserva una alta nitidez en los bordes y en las regiones de alto detalle, ya que cada píxel se toma exclusivamente de la imagen con mayor peso. Sin embargo, esta estrategia introduce transiciones visibles entre imágenes adyacentes, especialmente en las zonas de solape, donde aparecen costuras apreciables.

En la Figura 8 se presenta el resultado utilizando multi-band blending. En este caso, las transiciones entre imágenes son considerablemente más suaves, reduciendo de forma efectiva la visibilidad de las costuras. Este comportamiento se debe a la combinación multi-escala de las imágenes, que distribuye la mezcla en distintas frecuencias espaciales. A cambio, se observa un ligero suavizado de la imagen final, especialmente en zonas con alto contraste, así como un mayor coste computacional respecto al método max-weight.

En conjunto, ambos resultados reflejan el compromiso clásico entre nitidez local y suavidad en las transiciones, siendo max-weight más adecuado cuando se prioriza el detalle, y multi-band blending preferible cuando el objetivo principal es la continuidad visual del panorama.

La Tabla 5 recoge, para cada par de imágenes consecutivas, el número de emparejamientos iniciales, el número de inliers tras RANSAC y las traslaciones estimadas en los ejes horizontal y vertical. Se observa que, aunque el número de matches es elevado en todos los casos, el filtrado robusto reduce significativamente el conjunto a inliers coherentes, lo que confirma la eficacia del modelo de traslación estimado.

Las traslaciones horizontales (dx) presentan magnitudes consistentes entre pares consecutivos, lo que indica un movimiento dominante en el eje horizontal acorde con la captura panorámica. Por su parte, las componentes verticales (dy) muestran variaciones más pequeñas y ruidosas, justificando la necesidad de la corrección de drift vertical aplicada posteriormente. Los tiempos de emparejamiento se mantienen estables entre pares, evidenciando un comportamiento computacional uniforme del proceso.

En conjunto, los resultados cuantitativos y visuales confirman que la combinación de proyección cilíndrica, alineación basada en traslación robusta y estrategias de blending permite generar panoramas wide view coherentes incluso al utilizar un número elevado de imágenes.

5. Conclusiones

A lo largo de la práctica se ha comprobado la importancia de elegir adecuadamente detectores, descriptores y modelos geométricos según el problema. Mientras que los modelos basados en homografías son adecuados para escenas planas y pocos puntos de vista, los panoramas wide view requieren proyecciones no planas y modelos de alineación más restringidos. La comparación de estrategias de blending demuestra que la calidad visual final depende tanto de la geometría como de la fusión de intensidades.